

Data oddania: \_\_\_\_\_

Ocena: \_\_\_\_\_

Maciej Pracucik 216869

Adam Jóźwiak 216786

## **Zadanie 2: Sieć neuronowa służąca do korygowania pomiaru systemu lokalizacji**

### **1. Opis architektury sieci neuronowej**


1. Liczba warstw sieci neuronowej - 5 (Jedna warstwa wejścia, trzy warstwy ukryte, jedna warstwa wyjścia)
2. Liczebność neuronów w poszczególnych warstwach ukrytych - 30, 30, 30
3. Funkcja aktywacji zastosowana w poszczególnych warstwach - RELU (Rectified Linear Unit), która wyrażana jest wzorem  $y = \max(0, x)$ . Dla wszystkich wartości negatywnych przyjmuje wartość 0, natomiast dla wartości pozytywnych jest liniowa
4. Liczba próbek z poprzednich chwil czasowych wykorzystywanych przez sieć neuronową - 100
5. Wagach poszczególnych neuronów w warstwach

### **2. Opis algorytmu uczenia sieci neuronowej**

Algorytm używa klasy MLPRegressor z wysokopoziomowej biblioteki scikit-learn. Implementuje ona Multi-layer perceptron (MLP), który do nauki używa wstecznej propagacji, bez żadnej funkcji aktywacji w warstwie wyjściowej. Do funkcji straty wykorzystuje błąd kwadratowy, natomiast wynik działania sieci składa się z wartości stałych.

Na początku dane z plików xlsx wczytywane są do jednego dużego datasetu, pobieramy z niego dane i dzielimy je na oczekiwane wyniki oraz dane wejściowe. Następnie dzielone są na dane testowe i treningowe. Do danych wejściowych, zarówno testowych jak i treningowych dodawane są punkty z poprzednich chwil czasowych, a w następnej kolejności dane te są skalowane za pomocą zewnętrznej klasy StandardScaler. Tworzymy model MLP z parametrami: ilość neuronów w warstwach ukrytych oraz ilość tych warstw, typ funkcji aktywacji, solver do optymalizacji wag, ilość iteracji oraz wizualne przedstawienie kolejnych iteracji wraz z wartością straty. Do utworzonego modelu przekazywane są dane treningowe wejściowe i wyjściowe. Następnie tworzone są predykcje z wykorzystaniem naszej sieci neuronowej, najpierw z wartościami treningowymi, a następnie dla wartości testowych. Odpowiednio dla każdej z predykcji wyliczany jest błąd średniokwadratowy dla sprawdzenia poprawności i jakości sieci. Dla wizualizacji dane te są przedstawiane na wykresach.

### 3. Porównanie dystrybuant błędu pomiaru



Rysunek 1. Porównanie dystrybuant błędów pomiaru dla danych ze zbioru testowego oraz dla danych uzyskanych w wyniku filtracji przy użyciu sieci neuronowej.

### 4. Kod źródłowy programu do uczenia i testowania sieci neuronowej

Zdecydowaliśmy się nie umieszczać kodu źródłowego, ponieważ wykorzy-

stywaliśmy wysokopoziomowe biblioteki, przez co kod odpowiadający zarówno za uczenie jak i testowanie zajmuje bardzo mało linijek kodu.

## Literatura

- [1] T. Oetiker, H. Partl, I. Hyna, E. Schlegl. *Nie za krótkie wprowadzenie do systemu  $\text{\LaTeX}2\epsilon$* , 2007, dostępny online.
- [2] Dokumentacja biblioteki Scikit - Learn <https://scikit-learn.org/>
- [3] Pluralsight - tutorial Algorytm  $A^*$  <https://www.pluralsight.com/guides/machine-learning-neural-networks-scikit-learn>